

Автоматизация работы с запросами пользователей в службу поддержки с помощью ИИ

Powered by InnoSport team



mountains-desktop-wallpaper.jpeg



Пайплайн



01

Встречаем юзера



Считали запрос



Проверяем на
нежелательные
слова



Передаём модели

Gemma 4

переформулирует
запрос нужным
образом



Отправляем запрос
в базу знаний



>

Сделали чанкинг

>

Сделали векторную базу

>

Сделали семантический и
лексический поиск по базе

02

Ищем в базе знаний



>

Не отвечаем, если запрос
слишком общий

Предлагаем варианты
уточнения и возможность
ввести их самостоятельно

>

Пользователь выбирает один
из предложенных вариантов
или нажимает «Другое» и
пишет свой ответ.

03

Уточняем у пользователя

04

Даём полный ответ

>

С форматированием markdown

И не забываем показать
источники

>

Среднее время ответа

~5 сек до первого символа
~8 сек до полного ответа



ИнноСпорт!!

12 апреля 2010 в 18:27

Продолжаем задавать вопросы юзеру



12 апр 2010 | [Ответить](#)

[Поделиться](#) 3

[Мне нравится](#) 108

05

Переводим запрос на оператора

>

Определяем линию поддержки

>

Запрашиваем контактные данные
пользователя, чтобы упростить работу
сотруднику техподдержки



>

Администратор видит
Краткий вывод о качестве
поддержки

Возможные причины оценок

Выявленные системные
проблемы с ссылками на
обращения в они
упоминались

>


Можно выбрать обращения
для аудита:
Есть фильтры по временному
отрезку и по количеству
обращений

>

Доступен аудит по темам

06

Аудит обращений



07

Автоматизируем аудит

anapa2011.jpeg




Фици

Автодополнение

Составили 10000
вопросов на основе PDF

Когда пользователь
вводит запрос,
предлагаем ему
автодополнение с
помощью лексического
поиска





Обработка нецензурной лексики



Смотрим по словарю

LLM оценивает цензурность

Нейронка предлагает юзеру тактичный вариант обращения, если в нём есть рациональное зерно



Поиск по базе знаний

Предобработка

Контент PDF рекурсивно разбивается на чанки по 400 символов

Эмбединги строим сами с помощью
mxbai-embed-large

Индекс для семантического поиска, индекс для лексического поиска в MongoDB

Вызов тулзы

Моделька переформулирует запрос и вызывает тул

Тул получает релевантные чанки из MongoDB

Затем идёт в модель реранкер
cross-encoder-russian-msmarco

Ранжирует и передаёт модели как результат выполнения тулзы

Модель может запросить контент из PDF из соседних чанков для точности контекста



Классификация линии поддержки

>01

Разметили вручную 200
обращений

Скормили GPT-6.0-astra

Подготовили хорошие
примеры вопросов в L1/L2

>02


Записали эти вопросы в
промт нашей модели

>03

Модель получает и
анализирует запрос
пользователя

Определяет на какую линию
техподдержки отправить
обращение

Админ панель



Мы показываем
Тему и подтемы обращения
Оценку пользователя
Саммари диалога с агентом
Статистику по обращениям
с разделением по темам

Можно настроить
Аудит обращений
Ежедневную рассылку на
почту

Наша команда

01 **MainStorne**

Дмитрий Бевз

02 **PoweredDeveloper**


Михаил Истомин


03 **ArtemSBulgakov**

Артём Булгаков

04 **keamka**

Никита Лисицкий





nizhniy-novgorod-2026.jpeg



Демка